

Análisis Matemático para Inteligencia Artificial

Martín Errázquin (merrazquin@fi.uba.ar)

Especialización en Inteligencia Artificial

Clase 3

Proyección Ortogonal

$$\Pi(\Pi(v)) = \Pi(P \cdot v) = P^2 \cdot v$$

$$v \xrightarrow{\Pi} ? \xrightarrow{\Pi} ? \xrightarrow{\Pi} ?$$

Matriz de proyección

Proyección

$$\Pi(v) = \underbrace{P}_{n \times n} \cdot \underbrace{v}_n$$

Sea V un EV y $S \subset V$ un SEV. Una transformación lineal $\Pi : V \rightarrow S$ es una proyección si $\Pi^2 = \Pi \circ \Pi = \Pi$

Esto significa que la matriz de transformación asociada a la proyección cumple con la propiedad de idempotencia: $[\Pi]^2 = [\Pi]$.

$$x \in S? \xrightarrow{\Pi} x$$

$$P^2 = P$$

Proyección Ortogonal

Dado V un EV con p.i. y $S \subset V$ un SEV, el objetivo es dado $v \in V$ hallar $\tilde{v} \in S$ que sea "lo más parecido posible" a v .


$$d(v, s)$$

$$\tilde{v} \in S : \tilde{v} = \arg \min_{s \in S} \|v - s\|$$

$$(v - \tilde{v}) \in S^\perp$$

Además vale que $\langle v - \tilde{v}, s \rangle = 0, \forall s \in S$

Obs: La ortogonalidad de la proyección tiene que ver con el p.i. que se use.



Teorema de proyección

Sea \mathbb{V} un EV de dimensión finita con p.i. $\langle \cdot, \cdot \rangle$, S un SEV. Dado $v \in \mathbb{V}$ existe un único $\tilde{v} \in S$ tal que

$$\|v - \tilde{v}\| \leq \|v - u\|, \quad \forall u \in S$$

¿Cómo hallar la proyección?

Sea \mathbb{V} un EV de dimensión n con p.i. $\langle \cdot, \cdot \rangle$, y $S \subset \mathbb{V}$ un SEV, $\dim(S) = m \geq 1$, y sea $B = \{s_1, \dots, s_m\}$ una BON de S . Buscamos encontrar la proyección de $\tilde{v} \in S$ de $v \in \mathbb{V}$ ($\tilde{v} = \Pi_S(v)$). Proyección ortogonal de v sobre S

Como $\tilde{v} \in S$, $\tilde{v} = \sum_{i=1}^m \alpha_i s_i \Rightarrow$ busco los coeficientes que minimizan $\|v - \sum_{i=1}^m \alpha_i s_i\|$. El problema puede escribirse como:

$$\|v - \tilde{v}\|$$

$$\Pi_S(v) = \sum_{i=1}^m \alpha_i s_i = B\alpha, \quad B = [s_1, \dots, s_m], \quad \alpha = [\alpha_1, \dots, \alpha_m]^T \in \mathbb{R}^m$$

$= \tilde{v}$ $= \begin{pmatrix} | & & | \\ s_1 & \dots & s_m \\ | & & | \end{pmatrix} \in \mathbb{R}^{n \times m}$ $= \begin{pmatrix} \alpha_1 \\ \vdots \\ \alpha_m \end{pmatrix}$

¿Cómo hallar la proyección?

$$v - \tilde{v} \perp s \quad \forall s \in S$$

Como por definición $\langle v - \Pi_S(v), s \rangle = 0, \forall s \in S$, debo resolver el siguiente sistema de ecuaciones:

$$\langle x, y \rangle = x^T y = y^T x$$

producto escalar

$$\begin{cases} \langle v - \Pi_S(v), s_1 \rangle = 0 \\ \vdots \\ \langle v - \Pi_S(v), s_m \rangle = 0 \end{cases} \Rightarrow \begin{cases} s_1^T (v - B\alpha) = 0 \\ \vdots \\ s_m^T (v - B\alpha) = 0 \end{cases} \Rightarrow \begin{pmatrix} -s_1^T \\ \vdots \\ -s_m^T \end{pmatrix} (v - B\alpha) = \vec{0}$$

$\xrightarrow{B^T}$

$$B^T (v - B\alpha) = 0 \Leftrightarrow B^T v = \underline{B^T B} \alpha \Leftrightarrow \alpha = (B^T B)^{-1} B^T v$$

$$\begin{aligned} \tilde{v} &= B \cdot \alpha \\ &= B (B^T B)^{-1} B^T v \\ &= \underbrace{B (B^T B)^{-1} B^T}_{P.v} v \end{aligned}$$

$$\Pi_S = \underline{B (B^T B)^{-1} B^T} = P$$

Observación: Si B es una BON entonces $P_{\Pi_S} = BB^T$.

Aplicación: Cuadrados Mínimos

$$\hat{A}x=y \quad \sim A \in \mathbb{R}^{m \times n} \wedge \det(A) \neq 0 \Rightarrow x=A^{-1}y$$

Supongamos que tenemos un sistema sobredeterminado de la forma:

subdeterminado

$$\boxed{} \quad m < n$$
$$\boxed{} \quad m > n$$

$$Ab = y, \quad A \in \mathbb{R}^{m \times n}, \quad b \in \mathbb{R}^n, \quad y \in \mathbb{R}^m, \quad \underline{m > n}.$$

b es la solución de cuadrados mínimos

Como $m > n$, puede que no exista b que satisfaga todas las m ecuaciones, entonces busco la solución que más se acerque (busco $\text{Proy}_{\text{Col}(A)}y$)

$$b = (A^T A)^{-1} A^T y \Rightarrow P = A(A^T A)^{-1} A^T \quad \text{MULTICOLINEALIDAD}$$

$\beta_1, \dots, \beta_n \in \mathbb{R}$

$$S = \text{Col}(A)$$

$$\sim A = \begin{pmatrix} | & & | \\ a_1 & \dots & a_n \\ | & & | \end{pmatrix} \Rightarrow \text{Col}(A) = \langle \begin{pmatrix} | \\ a_1 \\ | \end{pmatrix}, \dots, \begin{pmatrix} | \\ a_n \\ | \end{pmatrix} \rangle$$

$$\underbrace{\beta_1 \begin{pmatrix} | \\ a_1 \\ | \end{pmatrix} + \dots + \beta_n \begin{pmatrix} | \\ a_n \\ | \end{pmatrix}}_{\sim y} = \begin{pmatrix} | \\ y \\ | \end{pmatrix}$$

Ya vimos que el ajuste por cuadrados mínimos funciona en la teoría, ahora veámoslo funcionar en la práctica!

Autovalores y Autovectores: definición

Sea $A \in \mathbb{K}^{n \times n}$, \mathbb{R} o \mathbb{C} diremos que $\lambda \in \mathbb{K}$ es un **autovalor** (ava) de A y $x \in \mathbb{K}^n$, $x \neq 0$ es un **autovector** (ave) asociado a λ si:

(λ, x)
ava ave \rightarrow dirección

$$Ax = \lambda x$$

Interpretación geométrica: A cada vector que se encuentre en la dirección de x , la transformación $T(x) = Ax$ lo contrae (o expende) por un factor λ .

Importante: un autovalor puede ser nulo, un autovector no.

Sea (λ, x) par ave-ave de A , $y = k \cdot x$ con $k \in \mathbb{K} \neq 0$

$$A \cdot y = A \cdot (k \cdot x) = k \cdot A \cdot x = \underbrace{k \cdot \lambda \cdot x}_{\substack{\text{producto} \\ \text{entre } \mathbb{K}'\text{'s}}} = \lambda (k \cdot x) = \lambda \cdot y$$

\uparrow
escalar

si (λ, x) es ave-ave de $A \Rightarrow \forall k_{\neq 0} (\lambda, k \cdot x)$ También

Autovalores y Autovectores: algunas aplicaciones

- 1 Geometría: curvas planas o superficies.
- 2 Sistemas dinámicos.
- 3 Análisis del comportamiento de sistemas de ecuaciones diferenciales.
- 4 Análisis de estabilidad.
- 5 Cadenas de Markov.
- 6 Grafos.
- 7 Reducción de dimensiones.
- 8 Cálculo de resonancias del sistema.
- 9 PageRank.

Hallando los autovalores

Dada $A \in \mathbb{K}^{n \times n}$, \mathbb{R} o \mathbb{C} , $\lambda \in \mathbb{K}$ es un autovalor de A si λ es un cero del polinomio característico, $p(\lambda)$, de A :

$$n = \sum_i m_a(\lambda_i)$$

$\mathbb{R} \rightarrow \mathbb{R}$

$$p(\lambda) = \det(A - \lambda I)$$

$$\begin{aligned} \exists x \neq 0 / Ax = \lambda x \\ Ax - \lambda x = 0 \\ (A - \lambda I) \cdot x = 0 \end{aligned}$$

$$\Downarrow \det(A - \lambda I) = 0$$

Observación: Puede ocurrir que algún λ sea raíz múltiple de $p(\lambda)$.

Se llama **multiplicidad algebraica**, m_a , a la cantidad de veces que λ aparece como raíz.

$$1 \leq m_g(\lambda) \leq m_a(\lambda) \leq n$$

Se llama **multiplicidad geométrica**, m_g , del autovalor λ , a la cantidad de autovectores l.i. asociados a λ .

$$A = \begin{pmatrix} 1 & -1 \\ 1 & 0 \end{pmatrix} \rightarrow p(\lambda) = \begin{vmatrix} 1-\lambda & -1 \\ 1 & -\lambda \end{vmatrix} = -1\lambda + \lambda^2 + 1 = (\lambda-2)^2 = 0 \Rightarrow \lambda_1 = 2$$

$\lambda_2 = 2$
 $m_a(2) = 2$

ave?
 $(A - 2I)\vec{x} = \vec{0}$

$$\begin{pmatrix} 2 & -1 \\ 1 & -2 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$\begin{cases} 2x - y = 0 \\ x - 2y = 0 \end{cases} \Rightarrow \begin{matrix} 0=0 \vee y \\ x=2y \end{matrix}$$

$$\vec{x} = \begin{pmatrix} 2y \\ y \end{pmatrix} = y \begin{pmatrix} 2 \\ 1 \end{pmatrix}$$

$m_g(2) = 1$

Propiedades de los autovectores

Dada $A \in \mathbb{K}^{n \times n}$, el conjunto de todos los autovectores asociados al autovalor λ generan un subespacio de \mathbb{K}^n (**autoespacio** de A respecto de λ). El conjunto de todos los autovectores de A se llama **autoespectro**.

Si λ es un autovalor de $A \in \mathbb{K}^{n \times n}$, el **autoespacio** E_λ asociado es la solución al sistema homogéneo $(A - \lambda I)x = 0$.

Teorema: Los autovectores x_1, \dots, x_n de una matriz $A \in \mathbb{R}^{n \times n}$ con n autovalores distintos de $\lambda_1, \dots, \lambda_n$ son linealmente independientes. Es decir, forman una base de \mathbb{R}^n .
(Handwritten note: (λ_1, x_1) ... (λ_n, x_n) con todos $\lambda_i \neq \lambda_j \Rightarrow \beta = \{x_1, \dots, x_n\}$ base de \mathbb{R}^n)

Teorema: Si $A \in \mathbb{R}^{n \times n}$ es simétrica, entonces existe una base ortonormal correspondiente a un espacio vectorial formado por autovectores de A y además $\lambda_i \in \mathbb{R}, \forall i = 1, \dots, n$.
(Handwritten note: $p(\lambda) = \lambda^2 + 1 = 0 \rightarrow \lambda_1 = i, \lambda_2 = -i$)

Ejemplo

$$A = \begin{pmatrix} 2 & -3 \\ 2 & 5 \end{pmatrix} \quad \dots \quad \lambda_1 = 1 \\ \lambda_2 = 4$$

$$(A - I)\vec{x} = \vec{0}$$

$$\dots \vec{x} = \alpha \begin{pmatrix} 1 \\ 1 \end{pmatrix} \Rightarrow E_1 = \left\langle \begin{pmatrix} 1 \\ 1 \end{pmatrix} \right\rangle$$

$$m_f(1) = m_e(1)$$

$$m_f(-1) = m_e(-1)$$

\Downarrow

$$(A - 4I)\vec{x} = \vec{0}$$

$$\dots \vec{x} = \alpha \begin{pmatrix} 1 \\ 2 \end{pmatrix} \Rightarrow E_2 = \left\langle \begin{pmatrix} 1 \\ 2 \end{pmatrix} \right\rangle$$

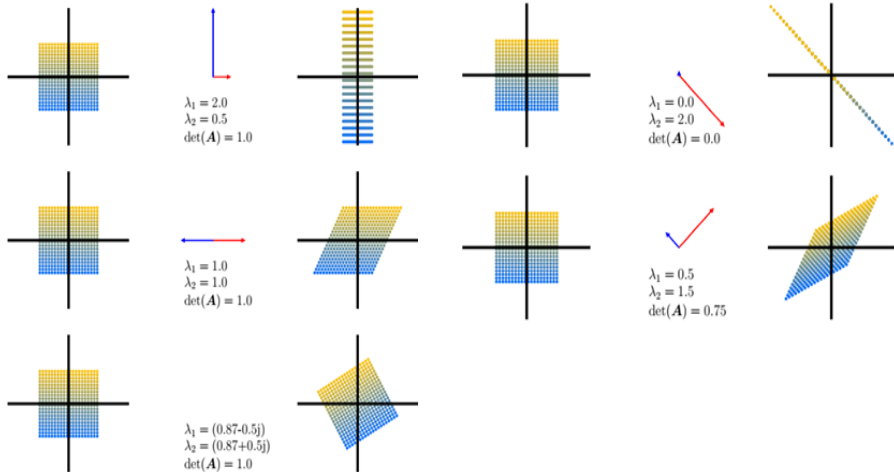
$$B = \left\{ \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \begin{pmatrix} 1 \\ 2 \end{pmatrix} \right\}$$

\Downarrow

$$D = \begin{pmatrix} 1 & 0 \\ 0 & -4 \end{pmatrix} \quad S = \begin{pmatrix} 1 & 1 \\ 1 & 2 \end{pmatrix} \Leftarrow A \text{ is diag.}$$

Interpretación gráfica (Mathematics for Machine Learning)

Sea $A \in \mathbb{K}^{n \times n}$: Área: $\det(A) = \prod_{i=1}^n \lambda_i$ y Perímetro: $Tr(A) = \sum_{i=1}^n \lambda_i$




Diagonalización

Definición:

Una matriz $A \in \mathbb{K}^{n \times n}$ es diagonalizable si $\exists S \in \mathbb{K}^{n \times n}$ no singular (es decir, tiene inversa) tal que:

$$S^{-1}AS = D \Leftrightarrow A = S \cdot D \cdot S^{-1}$$

donde D es una matriz *diagonal*.



Teorema: Sea $A \in \mathbb{K}^{n \times n}$ es diagonalizable sii A tiene n autovectores linealmente independientes.

$$A \begin{pmatrix} \lambda_1 & v_1 \\ \vdots & \vdots \\ \lambda_n & v_n \end{pmatrix} \Rightarrow S = \begin{pmatrix} | & & | \\ v_1 & \dots & v_n \\ | & & | \end{pmatrix}$$
$$D = \begin{pmatrix} \lambda_1 & & 0 \\ & \ddots & \\ 0 & & \lambda_n \end{pmatrix}$$
$$B = \{v_1, \dots, v_n\}$$

$$\begin{matrix} & y & & \\ & \uparrow & \uparrow & S \\ & \dots & \dots & \\ \lambda_1 & \lambda_2 & \dots & \lambda_n & D \\ \alpha_1 & \alpha_2 & \dots & \alpha_n & \\ & \downarrow & \downarrow & S^{-1} \\ & x & & \end{matrix}$$

Conclusiones para $A \in \mathbb{K}^{n \times n}$

- 1 A es diagonalizable \Rightarrow los vectores columna de la matriz de diagonalización S son los autovectores de A y los elementos de D son los autovalores de A .
- 2 S no es única, se pueden reordenar columnas, etc $\Rightarrow D$ será distinta.
- 3 A tiene n autovalores distintos \Rightarrow los autovectores correspondientes son l.i. $\Leftrightarrow A$ es diagonalizable. $\rightarrow m_a(\lambda_i) = 1 \forall i \Rightarrow m_a(\lambda_i) = 1 = m_g(\lambda_i) \forall i$
- 4 A tiene menos de n autovectores l.i. $\Leftrightarrow A$ no es diagonalizable.
- 5 Si hay autovalores repetidos y si:
 - $m_a = m_g$ (en los ava repetidos) \Rightarrow los ave son l.i.
 - $m_a > m_g$ (en un ava repetido) $\Rightarrow A$ no es diagonalizable.
- 6 Si $A \in \mathbb{C}^{n \times n}$ es una matriz hermítica ($A = \overline{A}^T = A^H$) $\Rightarrow A$ es diagonalizable y las columnas forman una BON.
- 7 A es diagonalizable $\Rightarrow A^n = SDS^{-1}SDS^{-1} \dots = SD^nS^{-1}$

$$A^{1000} = \underbrace{A \cdot A \cdot \dots \cdot A}_{1000}$$

$$D^k = \begin{pmatrix} \lambda_1^k & 0 \\ 0 & \ddots & 0 \\ 0 & \ddots & \lambda_n^k \end{pmatrix}$$

$$= \underbrace{S \cdot D \cdot \dots \cdot D \cdot S^{-1}}_{n \text{ veces}} = S \cdot D^n \cdot S^{-1}$$

Recordar que está disponible la encuesta de clase! Completarla es cortito y sirve para ir monitoreando el estado del curso.

¿Dónde encontrarla? En la hoja de notas (e.g. "Notas CEIA 10Co2024"), abajo de todo, junto al link de las grabaciones de las clases.